NETTOYAGE DES DONNÉES

- **Valeurs manquantes (NaN / Null)**
- **Doublons (lignes identiques)**
- **Valeurs aberrantes et extrêmes (outliers)**
- **Types de données incorrects (ex. texte au lieu de numérique)**
- **Valeurs impossibles ou invalides (ex. âge négatif)**
- **Déséquilibre des classes (ex. 99 % classe 0 / 1 % classe 1)**
- **Fuite de données (*Data Leakage*)**
- **Colonnes ou variables non pertinentes pour le modèle**
- **Identifiants uniques et colonnes inutiles (ex. user_id, transaction_id)**
- **Colonnes à variance nulle ou quasi-nulle (valeurs constantes)**
- **Échelles de variables très différentes (ex. âge vs salaire)**
- **Erreurs de saisie et espaces parasites dans le texte**
- **Casse incohérente (majuscules / minuscules)**
- **Catégories rares ou mal libellées**
- **Incohérences logiques (ex. âge < années d'expérience)**
- **Formats de dates et d'heures incohérents**
- **Variables fortement corrélées ou redondantes**
- **Cardinalité élevée des variables catégorielles (trop de modalités)**
- **Données bruitées ou mesures instables**
- **Problèmes d'encodage des caractères (accents, caractères spéciaux)**

EXPLORATION DES DONNÉES

- Dimensions du dataset (nombre de lignes et de colonnes)
- Aperçu des premières et dernières lignes (head() / tail())
- Noms et description des variables
- Types de données de chaque variable
- Valeurs manquantes par variable
- Nombre de doublons

- Nombre de valeurs uniques par variable
- Statistiques descriptives (moyenne, médiane, minimum, maximum, écart-type)
- Distribution des variables numériques
- Distribution des variables catégorielles
- Répartition de la variable cible (target / Class)
- Détection des valeurs aberrantes (boxplots, IQR, etc.)
- Analyse de la dispersion des variables (variance, écart-type)
- Analyse des corrélations entre variables
- Matrice de corrélation / heatmap
- Relations entre les variables explicatives et la variable cible
- Comparaison des distributions selon la classe cible
- Analyse des variables fortement corrélées ou redondantes
- Visualisation des principales relations entre variables (scatterplots, graphiques, etc.)
- Identification des premières anomalies et incohérences à traiter

FONCTIONS DE TRAITEMENT DES DONNÉES

Exploration

- **Dimensions** → data.shape
- **Premières lignes** → data.head()
- **Dernières lignes** → data.tail()
- **Noms des colonnes** → data.columns
- **Types des variables** → data.dtypes
- **Informations générales** → data.info()
- **Valeurs manquantes** → data.isnull().sum()
- **Total des valeurs manquantes** → data.isnull().sum().sum()
- **Doublons** → data.duplicated().sum()
- **Valeurs uniques** → data.nunique()
- **Modalités d'une variable** → data["Class"].unique()
- **Fréquence des modalités** → data["Class"].value_counts()
- **Statistiques descriptives** → data.describe()

- **Minimum** → data.min()
- **Maximum** → data.max()
- **Moyenne** → data.mean()
- **Médiane** → data.median()
- **Écart-type** → data.std()
- **Variance** → data.var()
- **Quantiles** → data.quantile()
- **Corrélations** → data.corr()
- **Corrélation avec Class** → data.corr(numeric_only=True)["Class"].sort_values()

🧹 Nettoyage

- **Supprimer les doublons** → data.drop_duplicates()
- **Supprimer les valeurs manquantes** → data.dropna()
- **Remplacer les valeurs manquantes** → data.fillna()
- **Convertir un type** → data.astype()
- **Convertir en numérique** → pd.to_numeric()
- **Supprimer les espaces** → data["colonne"].str.strip()
- **Passer en minuscules** → data["colonne"].str.lower()
- **Passer en majuscules** → data["colonne"].str.upper()
- **Remplacer des valeurs** → data.replace()
- **Sélectionner selon une condition** → data.loc[...]
- **Filtrer avec une condition** → data.query(...)
- **Supprimer une colonne** → data.drop(columns=[...])
- **Convertir une date** → pd.to_datetime()
- **Vérifier les valeurs rares** → data["colonne"].value_counts()
- **Vérifier les variables constantes** → data.nunique()
- **Vérifier la variance** → data.var()
- **Vérifier les outliers** → data.describe() / data.quantile()
- **Vérifier le déséquilibre des classes** → data["Class"].value_counts(normalize=True)
- **Vérifier les corrélations** → data.corr()
- **Détecter le Data Leakage** → **analyse du contexte des variables** (pas une fonction Pandas unique)